

Sprawozdanie  
Wprowadzenie do Sztucznej Inteligencji  
Laboratoria 2

Kamil Matejuk


14.11.2021r

## Metodyka testów


Efekty treningu sieci zostaną przetestowane na 3 zbiorach danych:

- zbiór testowy MNIST (10000 elementów) - oznaczony *ZT1*
- zbiór testowy stworzony przeze mnie (30 elementów) - oznaczony *ZT2*
- zbiór testowy stworzony przez osobę trzecią (30 elementów) - oznaczony *ZT3*


Zbiór MNIST został przygotowany w postaci odpowiedniej dla sieci neuronowej, natomiast zbiory *ZT2* i *ZT3* muszą zostać odpowiednio zmienione. W wersji podstawowej, dla każdego obrazu został zwiększony kontrast, następnie zmieniono RGB na skalę szarości, oraz zmapowano wartości pixeli na 0 lub 1. Finalnie obrazy zostały zeskalowane do rozmiaru 28 x 28. Dodatkowo, dla każdego ze zbiorów *ZT2* i *ZT3* został stworzony dodatkowy zbiór (odpowiednio *ZT2\_PREPROCESSED* i *ZT3\_PREPROCESSED*), który dokładniej przystosował zdjęcia na potrzeby sieci. Z każdego zdjęcia została wycięta część zawierająca cyfrę, następnie zeskalowana do 20px, oraz wstawiona w obraz 28 x 28.



*ZT1*



*ZT2*



*ZT2\_PREPROCESSED*

## Wybór parametrów

Początkowe parametry do wyboru struktury sieci to:

- `batch_size = 8`
- `epochs = 10`
- `optimizer = adam`
- `loss = Sparse Categorical Crossentropy`

Każda sieć przyjmuje input rozmiaru (28 x 28). Ostatnią warstwą zawsze jest *Dense*, która łączy się z każdym elementem poprzedniej warstwy i tworzy wektor 10-elementowy na wyjściu (1 element odpowiada jednej kategorii). Poniżej będę testował warstwy ukryte po środku:

Struktura wewnętrzna sieci	<i>ZT1</i>	<i>ZT2</i>	<i>ZT2_PRE</i>	<i>ZT3</i>	<i>ZT3_PRE</i>	
Flatten() Dense(64)	0.114 97%	4.506 27%	2.872 63%	4.021 27%	4.158 53%	loss accuracy
Flatten() Dense(128)	0.101 98%	6.919 27%	3.429 60%	7.162 17%	4.882 57%	loss accuracy
Flatten() Dense(256)	0.126 98%	6.971 27%	4.221 60%	6.654 23%	5.564 63%	loss accuracy
Flatten() Dense(196) Dense(49)	0.096 98%	6.387 23%	4.806 67%	4.954 30%	2.724 70%	loss accuracy
Flatten() Dense(392) Dense(98) Dense(24)	0.122 98%	4.364 30%	2.442 53%	4.223 33%	2.817 67%	loss accuracy
Conv2D(32) MaxPool2D() Flatten()	0.061 99%	5.642 27%	3.361 67%	5.955 23%	3.196 63%	loss accuracy
Conv2D(32) MaxPool2D() Conv2D(32) MaxPool2D() Flatten()	0.051 99%	8.359 13%	1.831 80%	8.374 30%	2.769 63%	loss accuracy
Conv2D(32) MaxPool2D() Conv2D(32) MaxPool2D() Conv2D(32) MaxPool2D() Flatten()	0.079 99%	6.099 30%	1.682 80%	5.271 40%	2.703 70%	loss accuracy

Najbardziej optymalne wyniki zwraca sieć złożona z trzech zestawów (Conv2D + MaxPool2D).

## Wnioski

Dla danych ze zbioru MNIST, które są identycznie przygotowane jak dane na których sieć była uczona, w stosunkowo krótkim czasie da się osiągnąć wskaźnik prawidłowej rozpoznawalności powyżej 99%. Dla danych stworzonych przez osoby trzecie, bardzo ważne jest jak najdokładniejsze przygotowanie tych danych. Przy minimalnym przygotowaniu (*ZT2* i *ZT3*) sieć wskazuje poprawne wyniki w około  $30\% \pm 3\%$ . Natomiast dane preprocesowane podobnie do danych MNIST (*ZT2\_PREPROCESSED* i *ZT3\_PREPROCESSED*) potrafiły uzyskać około  $65\% \pm 10\%$ .